Nazwa robocza koncepcji: Model estymacji widma wielozakresowego ze standardowego obrazu

Opis I poziomu TRL: W wyniku prac badawczych z zakresu uczenia głębokiego oraz optyki komputerowej, zespół opracował nowy algorytm odtwarzania danych wielozakresowych ze zwykłego zdjęcia RGB (wykonanego np. aparatem w smartfonie). Zauważono, że klasyfikacja struktury powierzchni i gęstości materiałów z jego użyciem jest o 21,37% skuteczniejsza niż w dotychczasowych algorytmach analizy tekstur. Ponadto zauważono, że model posiada właściwości pozwalające na wykrywanie niewidocznych gołym okiem zmian chemicznych (takich jak poziom nawodnienia, procesy gnilne, utlenianie) wyłącznie na podstawie sposobu załamywania się światła dziennego na fotografowanym obiekcie. Rozwiązanie może mieć potencjalne zastosowanie w rolnictwie precyzyjnym oraz kontroli jakości żywności. Wstępna analiza wykazała, że wykrywanie wczesnych stadiów psucia się żywności lub chorób roślin z jego użyciem jest o 95% szybsze i wielokrotnie tańsze względem metod wymagających specjalistycznych kamer spektralnych.

Opis II poziomu TRL: Przeprowadzono wstępną analizę możliwych zastosowań algorytmu estymacji widma wielozakresowego ze standardowego obrazu RGB. Ustalono, że optymalnym kierunkiem rozwoju projektu będzie wdrożenie technologii w obszarze kontroli jakości żywności na potrzeby branży logistycznej, hurtowni spożywczych oraz sieci handlowych. Technologię można rozwinąć i zastosować na popularnych platformach mobilnych (Android oraz iOS), a także zintegrować z centralnymi systemami webowymi.

Optymalnym rozwiązaniem jest stworzenie aplikacji mobilnej działającej w architekturze hybrydowej (wykorzystującej moc obliczeniową urządzenia mobilnego do wstępnego przetwarzania i szybkiej klasyfikacji oraz chmurę obliczeniową do agregacji danych i głębokiej analizy), która stanowić będzie główny interfejs dla użytkownika. Aplikacja powinna być prosta, intuicyjna i zgodna z zasadą „im mniej kroków do rezultatu, tym lepiej" – cały proces po stronie użytkownika ograniczy się do wykonania zdjęcia partii produktów aparatem smartfona i natychmiastowego odczytania wyniku analizy na ekranie. Zauważono, że po odpowiedniej adaptacji i optymalizacji pod kątem urządzeń mobilnych, model może z powodzeniem służyć do błyskawicznej oceny stopnia świeżości, poziomu nawodnienia oraz wykrywania wczesnych procesów gnilnych w owocach i warzywach bez konieczności niszczenia próbek. Moduł automatycznego skanowania i klasyfikacji świeżości stanie się głównym komponentem docelowej aplikacji produkcyjnej.

Lista rzeczy potrzebnych do dalszego rozwoju projektu:

- **Infrastruktura sprzętowa i obliczeniowa:**

    - 3x stacja robocza wyposażona w wysokowydajne karty GPU do trenowania i optymalizacji głębokich sieci neuronowych,
    - serwer chmurowy (środowisko testowe i obliczeniowe) do hostowania modelu AI oraz bazy danych,
    - 4x smartfon testowy ze zróżnicowanymi matrycami aparatów (po 2 urządzenia dla systemów Android oraz iOS),
    - komora bezcieniowa z kontrolowanym oświetleniem oraz referencyjna kamera.
- **Oprogramowanie i narzędzia programistyczne:**
    - środowisko programistyczne IDE wraz z frameworkami do uczenia maszynowego (PyTorch / TensorFlow) i analizy obrazu (OpenCV),
    - narzędzia do tworzenia aplikacji mobilnych (Android Studio, Xcode, Flutter),
    - system kontroli wersji oraz oprogramowanie do zarządzania projektem.
- **Zaplecze organizacyjne i sieciowe:**
    - symetryczny dostęp światłowodowy do Internetu o wysokiej przepustowości,
    - środowisko do testów laboratoryjnych wraz z próbkami produktów spożywczych na różnych etapach świeżości.

III poziom TRL – Badania przemysłowe:

W ramach realizacji III poziomu gotowości technologicznej zostaną zrealizowane prace badawcze i inżynierskie nad odseparowanymi komponentami systemu w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – normalizacja zdjęć wykonywanych matrycami smartfonów w zróżnicowanych warunkach oświetleniowych. W ramach wskazanego modułu szczególny nacisk położono na poprawność separacji światła odbitego i kompensację balansu bieli, co jest kluczowe dla zachowania informacji o załamywaniu się światła dziennego na badanym obiekcie. Moduł wyposażono w zaimplementowany podsystem odrzucania kadrów nieostrych lub prześwietlonych przed przekazaniem ich do dalszej analizy.
- **Moduł rekonstrukcji widma wielozakresowego** – odtwarzanie pełnych danych wielozakresowych ze standardowego zdjęcia RGB z wykorzystaniem opracowanego algorytmu uczenia głębokiego. Rolą modułu jest wygenerowanie

precyzyjnej mapy spektralnej badanego produktu spożywczego. Szczególny nacisk położono na weryfikację dokładności wygenerowanego widma. Moduł wyposażono w podsystem kontroli i porównywania estymowanych danych wielozakresowych z danymi referencyjnymi, pozyskanymi w warunkach laboratoryjnych za pomocą fizycznej kamery hiperspektralnej. W ramach badań opracowano spójny system walidacji, którego miarą końcową jest współczynnik zgodności widmowej wyrażany w procentach.

- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – analiza zrekonstruowanego widma w celu wykrywania niewidocznych gołym okiem zmian chemicznych (poziom nawodnienia, wczesne procesy gnilne, utlenianie). We wskazanym module zweryfikowano możliwość klasyfikacji stanu produktów w czasie zbliżonym do rzeczywistego oraz zbadano obciążenie jednostek obliczeniowych (zarówno serwerowych, jak i procesorów mobilnych) oraz zużycie pamięci RAM. W module zastosowano tolerancję dla rozdzielczości mapy spektralnej, która zakłada, że szybkość klasyfikacji (utrzymanie przewagi 95% szybkości względem tradycyjnych metod) ma pierwszeństwo przed bezstratną rozdzielczością przestrzenną obrazu. Badania modułu skupiły się na znalezieniu optymalnego punktu trafności detekcji zmian chemicznych w stosunku do obciążenia procesora urządzenia.

Na poziomie wskazanego etapu określono również model matematyczny i architekturę kwantyzacji wag sieci neuronowej, które pozwalają na wielowątkowe wykonywanie obliczeń tensorowych oraz docelową kompresję modelu na potrzeby urządzeń mobilnych współpracujących z chmurą.

IV poziom TRL:

W ramach realizacji IV poziomu gotowości technologicznej zintegrowano opracowane wcześniej moduły w działający prototyp systemu i przeprowadzono prace badawcze w warunkach laboratoryjnych w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – przygotowano zestaw kontrolny 100 zdjęć próbek żywności wykonanych w formatach: jpg, png, heic oraz dng (RAW). Określono, że wewnętrzny format plików po normalizacji oświetlenia i separacji światła odbitego będzie miał rozszerzenie: *.nrgb (Normalized RGB). Wykonano 100 serii testów na zestawie kontrolnym. Algorytm wykazał pewne odchylenia w niektórych seriach testów dla formatów skompresowanych stratnie (jpg, heic). Ustalono, że na wynik ma wpływ wbudowane w systemy operacyjne smartfonów automatyczne odszumianie i wyostrzanie krawędzi przez procesor obrazu (ISP). Wprowadzono poprawkę do algorytmu (filtr neutralizujący ingerencję ISP) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.

- **Moduł rekonstrukcji widma wielozakresowego** – przygotowano zestaw kontrolny 100 plików wstępnie przetworzonych w formacie *.nrgb. Określono, że wygenerowane przez sieć neuronową mapy widmowe będą zapisywane w autorskim formacie macierzowym o rozszerzeniu: *.mspec (Multispectral Data). Wykonano po 100 serii testów dla zestawu kontrolnego, porównując wyniki z odczytami referencyjnej kamery hiperspektralnej. Algorytm wykazał pewne odchylenie w niektórych seriach testów przy odtwarzaniu pasma bliskiej podczerwieni. Ustalono, że na wynik ma wpływ konwersja precyzji zmiennoprzecinkowej (z FP32 na FP16) na różnych jednostkach obliczeniowych (GPU/NPU). Wprowadzono poprawkę do algorytmu normalizacji wag sieci i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.
- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – przygotowano zestaw kontrolny 100 plików map widmowych w formacie *.mspec (obejmujących produkty świeże oraz w początkowym stadium utleniania i gnicia). Wykonano po 100 serii testów dla zestawu kontrolnego plików. Podczas każdego testu rejestrowano wygenerowane raporty diagnostyczne (zapisywane w formacie *.frep – Freshness Report) oraz logowano czas analizy i obciążenie podzespołów. Algorytm wykazał pewne odchylenie w niektórych seriach testów dla produktów o silnie połyskliwej strukturze powierzchni (np. jabłka, pomidory). Ustalono, że na wynik ma wpływ punktowe przesterowanie kanałów jasności w miejscu bezpośredniego odbicia źródła światła. Wprowadzono poprawkę do algorytmu (maskowanie odblasków spekularnych) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.

Określenie ryzyk dla IV poziomu TRL wraz z koncepcją ich eliminacji:

W celu odniesienia skuteczności realizacji projektu zidentyfikowano kluczowe ryzyka dla etapu badań nad prototypem oraz określono priorytety (stopień procentowy) i sposoby ich wyeliminowania:

- **Ryzyko 1 (Szansa wystąpienia: 65%):** Niespójność wyników wstępnego przetwarzania i rekonstrukcji widma wynikająca z różnic sprzętowych w matrycach aparatów oraz układach obliczeniowych (SoC/NPU) różnych producentów smartfonów
    - **Rozwiązanie:** Rozszerzenie testów w badaniu o szersze spektrum jednostek mobilnych (różne architektury ARM i matryce światłoczułe) oraz wdrożenie macierzy kalibracyjnej pobierającej parametry optyczne z metadanych EXIF zdjęcia przed uruchomieniem głównego algorytmu.

- **Ryzyko 2 (Szansa wystąpienia: 45%):** Niekompatybilność przesyłanych danych pomiędzy modułem rekonstrukcji widma a modułem detekcji anomalii chemicznych i klasyfikacji świeżości.
    - **Rozwiązanie:** Dokonanie szczegółowego debugowania kodu, ustandaryzowanie wewnętrznej struktury nagłówków plików *.mspec oraz zastosowanie metody eliminacji wszystkich błędów i nieścisłości związanych z przesyłaniem danych „krok po kroku”.
- **Ryzyko 3 (Szansa wystąpienia: 30%):** Brak poprawnej komunikacji i synchronizacji pomiędzy modułami prototypu (zarówno po stronie urządzenia, jak i w komunikacji z chmurą) skutkujący zawieszaniem się procesu analizy lub wyciekami pamięci RAM podczas przetwarzania dużych partii zdjęć.
    - **Rozwiązanie:** Zastosowanie zaprogramowanych testów automatycznych (jednostkowych i integracyjnych) oraz uporządkowanie architektury prototypu z wykorzystaniem wzorca architektonicznego MVC – Model-View-Controller (pol. Model-Widok-Kontroler).