ZARZĄDZANIE PROJEKTEM INFORMATYCZNYM

Nazwa robocza koncepcji:

Model estymacji widma wielozakresowego ze standardowego obrazu

Opracowanie:
Jakub Sierocki, Mateusz Derbin

Spis treści

1. Opis I poziomu TRL 3
2. Opis II poziomu TRL 3
2.1. Lista rzeczy potrzebnych do dalszego rozwoju projektu 3
3. III poziom TRL – Badania przemysłowe 4
4. IV poziom TRL – Badania w warunkach laboratoryjnych 5
4.1. Określenie ryzyk dla IV poziomu TRL wraz z koncepcją ich eliminacji 6
5. Grupa docelowa oraz model komercjalizacji produktu 6
5.1. Grupa docelowa 6
5.2. Model biznesowy (sprzedażowy) 7
6. V poziom TRL – Weryfikacja koncepcji w środowisku zbliżonym do rzeczywistego 7

1. Opis I poziomu TRL

W wyniku prac badawczych z zakresu **uczenia głębokiego** oraz **optyki komputerowej**, zespół opracował nowy algorytm odtwarzania danych wielozakresowych ze zwykłego zdjęcia RGB (wykonanego np. aparatem w smartfonie). Zauważono, że klasyfikacja struktury powierzchni i gęstości materiałów z jego użyciem jest o **21,37% skuteczniejsza** niż w dotychczasowych algorytmach analizy tekstur. Ponadto zauważono, że model posiada właściwości pozwalające na wykrywanie niewidocznych gołym okiem *zmian chemicznych* (takich jak poziom nawodnienia, procesy gnilne, utlenianie) wyłącznie na podstawie sposobu załamywania się światła dziennego na fotografowanym obiekcie. Rozwiązanie może mieć potencjalne zastosowanie w **rolnictwie precyzyjnym** oraz **kontroli jakości żywności**. Wstępna analiza wykazała, że wykrywanie wczesnych stadiów psucia się żywności lub chorób roślin z jego użyciem jest o **95% szybsze** i wielokrotnie tańsze względem metod wymagających specjalistycznych kamer spektralnych.

2. Opis II poziomu TRL

Przeprowadzono wstępną analizę możliwych zastosowań algorytmu estymacji widma wielozakresowego ze standardowego obrazu RGB. Ustalono, że optymalnym kierunkiem rozwoju projektu będzie wdrożenie technologii w obszarze **kontroli jakości żywności** na potrzeby branży logistycznej, hurtowni spożywczych oraz sieci handlowych. Technologię można rozwinąć i zastosować na popularnych platformach mobilnych (*Android* oraz *iOS*), a także zintegrować z centralnymi systemami webowymi.

Optymalnym rozwiązaniem jest stworzenie **aplikacji mobilnej działającej w architekturze hybrydowej** (wykorzystującej moc obliczeniową urządzenia mobilnego do wstępnego przetwarzania i szybkiej klasyfikacji oraz chmurę obliczeniową do agregacji danych i głębokiej analizy), która stanowić będzie główny interfejs dla użytkownika. Aplikacja powinna być prosta, intuicyjna i zgodna z zasadą *„im mniej kroków do rezultatu, tym lepiej”* – cały proces po stronie użytkownika ograniczy się do wykonania zdjęcia partii produktów aparatem smartfona i natychmiastowego odczytania wyniku analizy na ekranie. Zauważono, że po odpowiedniej adaptacji i optymalizacji pod kątem urządzeń mobilnych, model może z powodzeniem służyć do błyskawicznej oceny stopnia świeżości, poziomu nawodnienia oraz wykrywania wczesnych procesów gnilnych w owocach i warzywach bez konieczności niszczenia próbek. **Moduł automatycznego skanowania i klasyfikacji świeżości** stanie się głównym komponentem docelowej aplikacji produkcyjnej.

2.1. Lista rzeczy potrzebnych do dalszego rozwoju projektu

Infrastruktura sprzętowa i obliczeniowa:

- 3x stacja robocza wyposażona w wysokowydajne karty GPU do trenowania i optymalizacji głębokich sieci neuronowych,
- serwer chmurowy (środowisko testowe i obliczeniowe) do hostowania modelu AI oraz bazy danych,

- 4x smartfon testowy ze zróżnicowanymi matrycami aparatów (po 2 urządzenia dla systemów *Android* oraz *iOS*),
- komora bezcieniowa z kontrolowanym oświetleniem oraz referencyjna kamera.

Oprogramowanie i narzędzia programistyczne:

- środowisko programistyczne IDE wraz z frameworkami do uczenia maszynowego (*PyTorch / TensorFlow*) i analizy obrazu (*OpenCV*),
- narzędzia do tworzenia aplikacji mobilnych (*Android Studio, Xcode, Flutter*),
- system kontroli wersji oraz oprogramowanie do zarządzania projektem.

Zaplecze organizacyjne i sieciowe:

- symetryczny dostęp światłowodowy do Internetu o wysokiej przepustowości,
- środowisko do testów laboratoryjnych wraz z próbkami produktów spożywczych na różnych etapach świeżości.

3. III poziom TRL – Badania przemysłowe

W ramach realizacji III poziomu gotowości technologicznej zostaną zrealizowane prace badawcze i inżynierskie nad odseparowanymi komponentami systemu w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – normalizacja zdjęć wykonywanych matrycami smartfonów w zróżnicowanych warunkach oświetleniowych. W ramach wskazanego modułu szczególny nacisk położono na poprawność separacji światła odbitego i kompensację balansu bieli, co jest kluczowe dla zachowania informacji o załamywaniu się światła dziennego na badanym obiekcie. Moduł wyposażono w zaimplementowany *podsystem odrzucania kadrów nieostrych lub prześwietlonych* przed przekazaniem ich do dalszej analizy.
- **Moduł rekonstrukcji widma wielozakresowego** – odtwarzanie pełnych danych wielozakresowych ze standardowego zdjęcia RGB z wykorzystaniem opracowanego algorytmu uczenia głębokiego. Rolą modułu jest wygenerowanie precyzyjnej mapy spektralnej badanego produktu spożywczego. Szczególny nacisk położono na weryfikację dokładności wygenerowanego widma. Moduł wyposażono w podsystem kontroli i porównywania estymowanych danych wielozakresowych z danymi referencyjnymi, pozyskanymi w warunkach laboratoryjnych za pomocą fizycznej kamery hiperspektralnej. W ramach badań opracowano spójny system walidacji, którego miarą końcową jest **współczynnik zgodności widmowej** wyrażany w procentach.
- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – analiza zrekonstruowanego widma w celu wykrywania niewidocznych gołym okiem zmian chemicznych (poziom nawodnienia, wczesne procesy gnilne, utlenianie). We wskazanym module zweryfikowano możliwość klasyfikacji stanu produktów w czasie zbliżonym do rzeczywistego oraz zbadano obciążenie jednostek obliczeniowych (zarówno serwerowych, jak i procesorów mobilnych) oraz zużycie pamięci RAM. W module zastosowano tolerancję dla rozdzielczości mapy spektralnej, która zakłada, że **szybkość klasyfikacji** (utrzymanie przewagi 95% szybkości względem tradycyjnych metod) ma pierwszeństwo przed bezstratną rozdzielczością przestrzenną obrazu. Badania modułu skupiły się na znalezieniu

optymalnego punktu trafności detekcji zmian chemicznych w stosunku do obciążenia procesora urządzenia.

Na poziomie wskazanego etapu określono również **model matematyczny i architekturę kwantyzacji wag sieci neuronowej**, które pozwalają na wielowątkowe wykonywanie obliczeń tensorowych oraz docelową kompresję modelu na potrzeby urządzeń mobilnych współpracujących z chmurą.

4. IV poziom TRL – Badania w warunkach laboratoryjnych

W ramach realizacji IV poziomu gotowości technologicznej zintegrowano opracowane wcześniej moduły w działający prototyp systemu i przeprowadzono prace badawcze w warunkach laboratoryjnych w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – przygotowano zestaw kontrolny 100 zdjęć próbek żywności wykonanych w formatach: *jpg, png, heic* oraz *dng (RAW)*. Określono, że wewnętrzny format plików po normalizacji oświetlenia i separacji światła odbitego będzie miał rozszerzenie: ***.nrgb** (*Normalized RGB*). Wykonano 100 serii testów na zestawie kontrolnym. Algorytm wykazał pewne odchylenia w niektórych seriach testów dla formatów skompresowanych stratnie (*jpg, heic*). Ustalono, że na wynik ma wpływ wbudowane w systemy operacyjne smartfonów automatyczne odszumianie i wyostrzanie krawędzi przez procesor obrazu (**ISP**). Wprowadzono poprawkę do algorytmu (filtr neutralizujący ingerencję ISP) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.
- **Moduł rekonstrukcji widma wielozakresowego** – przygotowano zestaw kontrolny 100 plików wstępnie przetworzonych w formacie ***.nrgb**. Określono, że wygenerowane przez sieć neuronową mapy widmowe będą zapisywane w autorskim formacie macierzowym o rozszerzeniu: ***.mspec** (*Multispectral Data*). Wykonano po 100 serii testów dla zestawu kontrolnego, porównując wyniki z odczytami referencyjnej kamery hiperspektralnej. Algorytm wykazał pewne odchylenie w niektórych seriach testów przy odtwarzaniu pasma bliskiej podczerwieni. Ustalono, że na wynik ma wpływ konwersja precyzji zmiennoprzecinkowej (z *FP32* na *FP16*) na różnych jednostkach obliczeniowych (**GPU/NPU**). Wprowadzono poprawkę do algorytmu normalizacji wag sieci i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.
- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – przygotowano zestaw kontrolny 100 plików map widmowych w formacie ***.mspec** (obejmujących produkty świeże oraz w początkowym stadium utleniania i gnicia). Wykonano po 100 serii testów dla zestawu kontrolnego plików. Podczas każdego testu rejestrowano wygenerowane raporty diagnostyczne (zapisywane w formacie ***.frep** – *Freshness Report*) oraz logowano czas analizy i obciążenie podzespołów. Algorytm wykazał pewne odchylenie w niektórych seriach testów dla produktów o silnie połyskliwej strukturze powierzchni (np. jabłka, pomidory). Ustalono, że na wynik ma wpływ punktowe przesterowanie kanałów jasności w miejscu bezpośredniego odbicia źródła światła. Wprowadzono poprawkę do algorytmu (*maskowanie odblasków spekularnych*) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.

4.1. Określenie ryzyk dla IV poziomu TRL wraz z koncepcją ich eliminacji

W celu odniesienia skuteczności realizacji projektu zidentyfikowano kluczowe ryzyka dla etapu badań nad prototypem oraz określono priorytety (stopień procentowy) i sposoby ich wyeliminowania:

- **Ryzyko 1 (Szansa wystąpienia: 65%):** Niespójność wyników wstępnego przetwarzania i rekonstrukcji widma wynikająca z różnic sprzętowych w matrycach aparatów oraz układach obliczeniowych (*SoC/NPU*) różnych producentów smartfonów.

Rozwiązanie: Rozszerzenie testów w badaniu o szersze spektrum jednostek mobilnych (różne architektury ARM i matryce światłoczułe) oraz wdrożenie macierzy kalibracyjnej pobierającej parametry optyczne z metadanych *EXIF* zdjęcia przed uruchomieniem głównego algorytmu.

- **Ryzyko 2 (Szansa wystąpienia: 45%):** Niekompatybilność przesyłanych danych pomiędzy modułem rekonstrukcji widma a modułem detekcji anomalii chemicznych i klasyfikacji świeżości.

Rozwiązanie: Dokonanie szczegółowego debugowania kodu, ustandaryzowanie wewnętrznej struktury nagłówków plików ***.mspec** oraz zastosowanie metody eliminacji wszystkich błędów i nieścisłości związanych z przesyłaniem danych „krok po kroku".

- **Ryzyko 3 (Szansa wystąpienia: 30%):** Brak poprawnej komunikacji i synchronizacji pomiędzy modułami prototypu (zarówno po stronie urządzenia, jak i w komunikacji z chmurą) skutkujący zawieszaniem się procesu analizy lub wyciekami pamięci RAM podczas przetwarzania dużych partii zdjęć.

Rozwiązanie: Zastosowanie zaprogramowanych testów automatycznych (jednostkowych i integracyjnych) oraz uporządkowanie architektury prototypu z wykorzystaniem wzorca architektonicznego **MVC – Model-View-Controller** (pol. *Model-Widok-Kontroler*).

5. Grupa docelowa oraz model komercjalizacji produktu

5.1. Grupa docelowa

W skład głównej grupy docelowej wchodzą podmioty z sektora **B2B** (*Business-to-Business*) działające w branży rolno-spożywczej, logistycznej oraz handlowej (*FMCG*), które poszukują szybkich, bezinwazyjnych i tanich metod weryfikacji jakości oraz świeżości produktów spożywczych (głównie owoców i warzyw). Bezpośrednimi użytkownikami końcowymi aplikacji mobilnej będą kontrolerzy jakości, magazynierzy, audytorzy dostaw oraz kierownicy działów świeżych produktów w wieku 22–55 lat, wykorzystujący smartfony służbowe w codziennej pracy operacyjnej. Do tej grupy kierowana będzie mobilna aplikacja skanująca współpracująca z chmurą obliczeniową.

Drugim segmentem odbiorców są średnie i duże gospodarstwa rolne oraz sadownicze (**rolnictwo precyzyjne**), a także instytucje i firmy ubezpieczeniowe szacujące szkody w uprawach, do których kierowana będzie usługa zaawansowanej analityki predykcyjnej oraz dostęp do interfejsu API pozwalającego na integrację algorytmu z wewnętrznymi systemami klasy *ERP/WMS*. Szacuje się, że wielkość rynku docelowego w samej Polsce obejmuje ponad **10 000 podmiotów** z sektora dystrybucji żywności (hurtownie spożywcze, centra logistyczne, sieci supermarketów) oraz około **150 000**

nowoczesnych gospodarstw towarowych zainteresowanych wdrażaniem rozwiązań z obszaru *AgriTech* i *FoodTech* (w skali całej Unii Europejskiej rynek ten przekracza kilkaset tysięcy potencjalnych klientów biznesowych).

5.2. Model biznesowy (sprzedażowy)

Model biznesowy opierał się będzie na dystrybucji oprogramowania w modelu **SaaS** (*Software as a Service*) i zostanie podzielony na dwa główne filary (segmenty):

- **Segment MŚP oraz użytkowników indywidualnych (mniejsze hurtownie, lokalne sklepy spożywcze, niezależni sadownicy i rolnicy):** Usługa dostępu do aplikacji mobilnej zostanie podzielona na wersję **Freemium** (darmową) oraz opcję **Premium** (płatną). W opcji darmowej użytkownik otrzyma możliwość wykonania do 50 skanów próbnych miesięcznie wraz z podstawowym odczytem wskaźnika świeżości, co pozwoli na bezkosztowe przetestowanie narzędzia i zbudowanie szerokiej rozpoznawalności marki w branży. W opcji płatnej (*Premium*), rozliczanej w formie abonamentu miesięcznego lub rocznego, udostępniona zostanie możliwość nielimitowanego skanowania partii towaru, wykrywania wczesnych procesów gnilnych w pełnej rozdzielczości widmowej, generowania szczegółowych raportów diagnostycznych (***.frep**) oraz eksportu dokumentacji kontrolnej do formatów PDF/CSV.
- **Segment instytucjonalny i korporacyjny (duże sieci handlowe, centra dystrybucyjne, zakłady przetwórstwa spożywczego):** W segmencie instytucjonalnym, do którego kierowana jest głównie usługa masowej kontroli jakości oraz integracji systemowej (API), sporządzana będzie **umowa licencyjna**. Pozwoli ona w pierwszym etapie (tzw. *okres pilotażowy*) za darmo korzystać z systemu rekonstrukcji widma i klasyfikacji świeżości w ograniczonych limitach ilościowych (np. do 1000 skanów lub dla jednego wybranego magazynu). Następnie, w zależności od wykupionej licencji (**opłata abonamentowa roczna**), klient biznesowy otrzyma kilka opcji płatnych do wyboru, dopasowanych do wewnętrznych potrzeb swojej organizacji – obejmujących m.in. integrację z systemami magazynowymi *WMS*, nielimitowaną przestrzeń w chmurze na dane historyczne, obsługę strumieni wideo z kamer na liniach sortowniczych oraz gwarantowane wsparcie techniczne (*SLA*).

6. V poziom TRL – Weryfikacja koncepcji w środowisku zbliżonym do rzeczywistego

W celu połączenia zaprogramowanych komponentów zostanie zastosowany wzorzec architektoniczny **MVC** (z ang. *Model-View-Controller*, pol. *Model-Widok-Kontroler*), który służy do organizowania struktury aplikacji. W tym celu zaprogramowany zostanie dodatkowy moduł **Kontrolera**. Jego zadaniem będzie koordynacja pracy aplikacji hybrydowej poprzez przyjmowanie danych obrazowych oraz macierzy widmowych i reagowanie na nie. Będzie on zarządzał aktualizacją modelu aplikacji oraz odświeżaniem widoków interfejsu użytkownika na urządzeniu mobilnym. W etapie zostaną przeprowadzone prace koncentrujące się na zweryfikowaniu komponentów i podstawowych podsystemów technologii w środowisku zbliżonym do rzeczywistego (symulowane warunki oświetlenia hali magazynowej oraz chłodni spożywczej).

- **Kontroler** – zostanie zaprogramowany celem koordynowania pracy pozostałych modułów systemu. W opisanym etapie zostanie sprawdzone działanie kontrolera i przeprowadzone testy jego stabilności (poprzez jego wielokrotne włączanie i wyłączanie oraz symulowanie przerw w połączeniu z chmurą; błędy powodujące destabilizację pracy kontrolera będą korygowane do momentu, aż zostanie wykonany pełny cykl bez błędów). Powyższe pozwoli zweryfikować, czy prawidłowo odbiera on dane wejściowe z aparatu, dokonuje ich podstawowej identyfikacji i prawidłowo przesyła je do wybranych modułów przetwarzania. W kontrolerze zostaną zdefiniowane wtyczki (interfejsy komunikacyjne) do wszystkich zaprogramowanych wcześniej modułów oraz podstawowa weryfikacja danych (i ich typów, m.in. walidacja formatów wejściowych *jpg, png, heic, dng* oraz pośrednich ***.nrgb, *.mspec, *.frep**), jakie mają wyjść do danego modułu. Zostanie także przetestowane działanie rozpoznawania danych dla poszczególnych modułów. W tym celu moduł zostanie poddany testom na danych kontrolnych dla każdej z wtyczek Kontrolera dedykowanej dla konkretnego modułu. Zostanie także dokonana weryfikacja reakcji modułu na dane celowo „uszkodzone" (np. zmieniony typ danych, niepełny nagłówek macierzy widmowej lub zerowy rozmiar pliku zdjęcia). W przypadku niewłaściwej reakcji zostanie dokonana analiza, która ustali przyczynę błędu. Następnie zostaną wprowadzone zmiany programistyczne w obszarze warunków weryfikujących zgodność danych. Pomyślny test prawidłowego działania kontrolera (tj. uzyskania zwrotu informacji o błędach w danych bez zawieszenia aplikacji) pozwoli na jego pełną integrację z wcześniej zaprogramowanymi modułami.
- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (zgodnie z wymogami weryfikacji w środowisku zbliżonym do rzeczywistego zwiększono bazę testową z 100 do **1000 plików zdjęć** partii owoców i warzyw wykonanych w symulowanych warunkach oświetlenia magazynowego, w zakresie prawidłowej normalizacji oświetlenia i konwersji do formatu ***.nrgb**). Analizie podlegała także kompletność znormalizowanych danych oraz skuteczność odrzucania kadrów poruszonych i prześwietlonych. Ewentualne błędy w opisanym zakresie (wynikające m.in. z migotania oświetlenia jarzeniowego *50 Hz* w halach magazynowych) zostaną wyeliminowane poprzez poprawki programistyczne i kolejne testy na tych samych 1000 plikach (aż do poprawnego skomunikowania się z modułem kontrolera i poprawnego odczytu poleceń otrzymanych z Kontrolera).
- **Moduł rekonstrukcji widma wielozakresowego** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (testu dokonano na próbnej bazie **1000 plików** wstępnie przetworzonych obrazów ***.nrgb**, w zakresie prawidłowej estymacji widma i generowania plików macierzowych ***.mspec**). Zweryfikowano jakość komunikacji danych pomiędzy urządzeniem mobilnym a serwerem obliczeniowym oraz kompatybilność z pozostałymi współpracującymi modułami systemu. Przeprowadzono procedurę sprawdzającą jakość zrekonstruowanych informacji widmowych na plikach testowych względem pomiarów referencyjnych. W przypadku błędów spowodowanych przeciążeniem kontrolera, przekroczeniem limitu czasu odpowiedzi (tzw. *timeout*) lub błędami alokacji pamięci modelu rekonstrukcji widma, zostaną one usunięte poprzez analizę wyników i dokonanie korekty programistycznej w kodzie (optymalizacja kolejkowania zadań i buforowania tensorów). Następnie ponownie zostanie wykonany test na tych samych 1000 plikach.

- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (testu dokonano na próbnej bazie **1000 plików** map widmowych ***.mspec** oraz sekwencji kadrów wideo, w zakresie prawidłowej detekcji zmian chemicznych i klasyfikacji świeżości w czasie zbliżonym do rzeczywistego). Zweryfikowano jakość odczytu danych wyjściowych w postaci poprawności generowanych raportów diagnostycznych (***.frep**) oraz wizualnej nakładki mapy świeżości prezentowanej na ekranie smartfona. Sprawdzono jakość komunikacji danych i kompatybilność z pozostałymi współpracującymi modułami systemu. W przypadku błędów spowodowanych przeciążeniem kontrolera lub modułu klasyfikacji podczas ciągłego skanowania partii towaru, zostaną one usunięte poprzez analizę wyników i dokonanie korekty programistycznej w kodzie. Następnie ponownie zostanie wykonany test na tych samych 1000 plikach.

7. Analiza SWOT projektu wraz z oszacowaniem prawdopodobieństwa

W celu uporządkowania i przeanalizowania informacji strategicznych dotyczących rozwijanej technologii estymacji widma wielozakresowego ze standardowego obrazu RGB, przeprowadzono **analizę SWOT** z podziałem na cztery główne grupy czynników (wewnętrzne pozytywne i negatywne oraz zewnętrzne pozytywne i negatywne). Dla każdego ze zidentyfikowanych czynników oszacowano procentowe prawdopodobieństwo jego wystąpienia, posiadania lub zrealizowania wraz z komentarzem analitycznym.

7.1. S (Strengths) – Mocne strony (czynniki wewnętrzne pozytywne)

- **Wysoka przewaga szybkości i niskiego kosztu wdrożenia względem kamer hiperspektralnych (prawdopodobieństwo utrzymania parametru: 95%).** *Komentarz:* Eliminacja konieczności zakupu specjalistycznego sprzętu optycznego na rzecz zwykłego aparatu w smartfonie oraz o 95% szybszy czas detekcji stanowią główny atut technologiczny potwierdzony już w badaniach laboratoryjnych.
- **Skuteczność klasyfikacji struktury powierzchni i zmian chemicznych wyższa o 21,37% od klasycznych algorytmów analizy tekstur (prawdopodobieństwo posiadania cechy: 92%).** *Komentarz:* Wysokie prawdopodobieństwo wynika z zastosowania autorskiego modelu uczenia głębokiego oraz walidacji na danych referencyjnych w formatach ***.nrgb** oraz ***.mspec**.
- **Nowoczesny interfejs mobilny oparty na zasadzie „im mniej kroków do rezultatu, tym lepiej" (szansa wystąpienia: 98%).** *Komentarz:* W tym obszarze nie są wymagane nadzwyczajne działania korygujące, ponieważ architektura MVC oraz proces skanowania jednym przyciskiem zostały precyzyjnie zaplanowane i zweryfikowane.
- **Skalowalna architektura hybrydowa łącząca obliczenia brzegowe (Edge AI) z chmurą obliczeniową oraz otwartym API (prawdopodobieństwo osiągnięcia: 90%).** *Komentarz:* Pozwala na jednoczesną obsługę klientów indywidualnych (aplikacja mobilna) oraz dużych sieci logistycznych (integracja z systemami WMS/ERP).

7.2. W (Weaknesses) – Słabe strony (czynniki wewnętrzne negatywne)

- **Wrażliwość algorytmu na skrajnie niekorzystne warunki oświetleniowe oraz silne odblaski spekularne na błyszczących owocach (prawdopodobieństwo wystąpienia problemu: 35%).** *Komentarz:* Świadomość tej słabej strony na wczesnym etapie pozwoliła na wdrożenie filtrów maskujących odblaski oraz podsystemu odrzucania kadrów prześwietlonych, co redukuje pierwotne ryzyko błędów.
- **Rozbieżność parametrów optycznych matryc aparatów oraz algorytmów ISP u różnych producentów smartfonów (prawdopodobieństwo wystąpienia: 85%).** *Komentarz:* Wymaga ciągłego utrzymywania i aktualizowania macierzy kalibracyjnej pobierającej dane z nagłówków EXIF dla nowych modeli telefonów wchodzących na rynek.
- **Zależność pełnej analityki wielozakresowej i generowania raportów zbiorczych od stabilnego połączenia internetowego z chmurą (prawdopodobieństwo wystąpienia utrudnień: 30%).** *Komentarz:* W magazynach podziemnych lub chłodniach o grubych ścianach zasięg sieci komórkowej bywa ograniczony, dlatego konieczne jest buforowanie plików ***.nrgb** w pamięci lokalnej urządzenia.
- **Wysokie zapotrzebowanie na moc obliczeniową GPU na etapie trenowania i douczania sieci neuronowej dla nowych gatunków żywności (prawdopodobieństwo wystąpienia bariery kosztowej: 40%).** *Komentarz:* Rozbudowa bazy wiedzy modelu o kolejne kategorie produktów wymaga utrzymania kosztownej infrastruktury serwerowej i laboratoryjnej.

7.3. O (Opportunities) – Szanse (czynniki zewnętrzne pozytywne)

- **Rosnący nacisk regulacyjny i ekonomiczny w Unii Europejskiej na redukcję marnowania żywności w łańcuchach dostaw (szansa na korzystny rozwój rynku: 85%).** *Komentarz:* Bardzo silna szansa rynkowa – sieci handlowe i centra dystrybucyjne aktywnie poszukują narzędzi zmniejszających straty magazynowe świeżych produktów.
- **Możliwość pozyskania dotacji badawczo-rozwojowej z funduszy UE lub NCBR na dalszą komercjalizację technologii (szansa na powodzenie: 40%).** *Komentarz:* Umiarkowany poziom procentowy wynika z dużej konkurencji w konkursach grantowych; staranne przygotowanie dokumentacji projektowej (zgodnej ze skalą TRL) pozwala jednak realnie zwiększyć szansę na uzyskanie finansowania.
- **Rozszerzenie zastosowań opracowanego silnika rekonstrukcji widma na inne branże, np. dermatologię mobilną lub kontrolę powłok lakierniczych (szansa wdrożenia w przyszłości: 55%).** *Komentarz:* Elastyczna budowa modułowa pozwala w kolejnych latach na dywersyfikację źródeł przychodu poza sektorem spożywczym.

7.4. T (Threats) – Zagrożenia (czynniki zewnętrzne negatywne)

- **Wprowadzenie przez wiodących producentów smartfonów natywnych sensorów wielospektralnych lub wbudowanych funkcji AI o podobnym działaniu (szacowane ryzyko wystąpienia: 20%).** *Komentarz:* Ryzyko w krótkim terminie jest niskie ze względu na koszty sprzętowe po stronie producentów telefonów, jednak w perspektywie kilkuletniej wymaga budowania przewagi w postaci wyspecjalizowanej bazy danych produktów i integracji B2B.

- **Opór personelu magazynowego oraz mniejszych hurtowni przed zastąpieniem tradycyjnej oceny organoleptycznej systemem algorytmicznym (szacowane ryzyko wystąpienia: 35%).** *Komentarz:* W celu minimalizacji tego zagrożenia wprowadzono darmowy plan Freemium (do 50 skanów) oraz bezpłatne wdrożenia pilotażowe budujące zaufanie do wskazań aplikacji.
- **Drastyczny wzrost cen energii oraz usług chmurowych (Cloud GPU) obniżający rentowność modelu subskrypcyjnego SaaS (szacowane ryzyko wystąpienia: 25%).** *Komentarz:* Zagrożenie to jest ograniczane poprzez kwantyzację wag sieci neuronowej (FP16) i przenoszenie części obliczeń bezpośrednio na procesory mobilne użytkowników.
- **Możliwa zmiana prawna i zaostrzenie przepisów UE (np. AI Act oraz normy certyfikacji systemów jakości żywności) wpływające strategicznie na dopuszczenie systemu do obrotu (szacowane ryzyko wystąpienia: 10%).** *Komentarz:* Choć jednostkowe ryzyko jest stosunkowo niskie (10%), przy kumulacji kilku czynników regulacyjnych może ono opóźnić komercjalizację, dlatego system raportowania ***.frep** od początku projektowany jest z zachowaniem pełnej przejrzystości i audytowalności wyników.