# ZARZĄDZANIE PROJEKTEM INFORMATYCZNYM

**Nazwa robocza koncepcji:**

## *Model estymacji widma wielozakresowego ze standardowego obrazu*

**Opracowanie:**
Jakub Sierocki, Mateusz Derbin

# Spis treści

1. Opis I poziomu TRL ..... 3
2. Opis II poziomu TRL ..... 3
2.1. Lista rzeczy potrzebnych do dalszego rozwoju projektu ..... 3
3. III poziom TRL – Badania przemysłowe ..... 4
4. IV poziom TRL – Badania w warunkach laboratoryjnych ..... 5
4.1. Określenie ryzyk dla IV poziomu TRL wraz z koncepcją ich eliminacji ..... 6
5. Grupa docelowa oraz model komercjalizacji produktu ..... 6
5.1. Grupa docelowa ..... 6
5.2. Model biznesowy (sprzedażowy) ..... 7
6. V poziom TRL – Weryfikacja koncepcji w środowisku zbliżonym do rzeczywistego ..... 7
7. Analiza SWOT projektu wraz z oszacowaniem prawdopodobieństwa ..... 9
7.1. S (Strengths) – Mocne strony (czynniki wewnętrzne pozytywne) ..... 9
7.2. W (Weaknesses) – Słabe strony (czynniki wewnętrzne negatywne) ..... 10
7.3. O (Opportunities) – Szanse (czynniki zewnętrzne pozytywne) ..... 10
7.4. T (Threats) – Zagrożenia (czynniki zewnętrzne negatywne) ..... 10
8. VI poziom TRL – Demonstracja modelu prototypu w warunkach zbliżonych do rzeczywistych ..... 11
8.1. Testy serwerowe (obciążeniowe) i testy użytkowe (usability) ..... 11
8.2. Efekt końcowy VI poziomu TRL ..... 12
8.3. Ryzyka technologiczne dla VI poziomu TRL wraz z koncepcją ich eliminacji ..... 12

# 1. Opis I poziomu TRL

W wyniku prac badawczych z zakresu **uczenia głębokiego** oraz **optyki komputerowej**, zespół opracował nowy algorytm odtwarzania danych wielozakresowych ze zwykłego zdjęcia RGB (wykonanego np. aparatem w smartfonie). Zauważono, że klasyfikacja struktury powierzchni i gęstości materiałów z jego użyciem jest o **21,37% skuteczniejsza** niż w dotychczasowych algorytmach analizy tekstur. Ponadto zauważono, że model posiada właściwości pozwalające na wykrywanie niewidocznych gołym okiem *zmian chemicznych* (takich jak poziom nawodnienia, procesy gnilne, utlenianie) wyłącznie na podstawie sposobu załamywania się światła dziennego na fotografowanym obiekcie. Rozwiązanie może mieć potencjalne zastosowanie w **rolnictwie precyzyjnym** oraz **kontroli jakości żywności**. Wstępna analiza wykazała, że wykrywanie wczesnych stadiów psucia się żywności lub chorób roślin z jego użyciem jest o **95% szybsze** i wielokrotnie tańsze względem metod wymagających specjalistycznych kamer spektralnych.

# 2. Opis II poziomu TRL

Przeprowadzono wstępną analizę możliwych zastosowań algorytmu estymacji widma wielozakresowego ze standardowego obrazu RGB. Ustalono, że optymalnym kierunkiem rozwoju projektu będzie wdrożenie technologii w obszarze **kontroli jakości żywności** na potrzeby branży logistycznej, hurtowni spożywczych oraz sieci handlowych. Technologię można rozwinąć i zastosować na popularnych platformach mobilnych (*Android* oraz *iOS*), a także zintegrować z centralnymi systemami webowymi.

Optymalnym rozwiązaniem jest stworzenie **aplikacji mobilnej działającej w architekturze hybrydowej** (wykorzystującej moc obliczeniową urządzenia mobilnego do wstępnego przetwarzania i szybkiej klasyfikacji oraz chmurę obliczeniową do agregacji danych i głębokiej analizy), która stanowić będzie główny interfejs dla użytkownika. Aplikacja powinna być prosta, intuicyjna i zgodna z zasadą *„im mniej kroków do rezultatu, tym lepiej”* – cały proces po stronie użytkownika ograniczy się do wykonania zdjęcia partii produktów aparatem smartfona i natychmiastowego odczytania wyniku analizy na ekranie. Zauważono, że po odpowiedniej adaptacji i optymalizacji pod kątem urządzeń mobilnych, model może z powodzeniem służyć do błyskawicznej oceny stopnia świeżości, poziomu nawodnienia oraz wykrywania wczesnych procesów gnilnych w owocach i warzywach bez konieczności niszczenia próbek. **Moduł automatycznego skanowania i klasyfikacji świeżości** stanie się głównym komponentem docelowej aplikacji produkcyjnej.

## 2.1. Lista rzeczy potrzebnych do dalszego rozwoju projektu

**Infrastruktura sprzętowa i obliczeniowa:**

- 3x stacja robocza wyposażona w wysokowydajne karty GPU do trenowania i optymalizacji głębokich sieci neuronowych,
- serwer chmurowy (środowisko testowe i obliczeniowe) do hostowania modelu AI oraz bazy danych,

- 4x smartfon testowy ze zróżnicowanymi matrycami aparatów (po 2 urządzenia dla systemów *Android* oraz *iOS*),
- komora bezcieniowa z kontrolowanym oświetleniem oraz referencyjna kamera.

**Oprogramowanie i narzędzia programistyczne:**

- środowisko programistyczne IDE wraz z frameworkami do uczenia maszynowego (*PyTorch / TensorFlow*) i analizy obrazu (*OpenCV*),
- narzędzia do tworzenia aplikacji mobilnych (*Android Studio, Xcode, Flutter*),
- system kontroli wersji oraz oprogramowanie do zarządzania projektem.

**Zaplecze organizacyjne i sieciowe:**

- symetryczny dostęp światłowodowy do Internetu o wysokiej przepustowości,
- środowisko do testów laboratoryjnych wraz z próbkami produktów spożywczych na różnych etapach świeżości.

## 3. III poziom TRL – Badania przemysłowe

W ramach realizacji III poziomu gotowości technologicznej zostaną zrealizowane prace badawcze i inżynierskie nad odseparowanymi komponentami systemu w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – normalizacja zdjęć wykonywanych matrycami smartfonów w zróżnicowanych warunkach oświetleniowych. W ramach wskazanego modułu szczególny nacisk położono na poprawność separacji światła odbitego i kompensację balansu bieli, co jest kluczowe dla zachowania informacji o załamywaniu się światła dziennego na badanym obiekcie. Moduł wyposażono w zaimplementowany *podsystem odrzucania kadrów nieostrych lub prześwietlonych* przed przekazaniem ich do dalszej analizy.
- **Moduł rekonstrukcji widma wielozakresowego** – odtwarzanie pełnych danych wielozakresowych ze standardowego zdjęcia RGB z wykorzystaniem opracowanego algorytmu uczenia głębokiego. Rolą modułu jest wygenerowanie precyzyjnej mapy spektralnej badanego produktu spożywczego. Szczególny nacisk położono na weryfikację dokładności wygenerowanego widma. Moduł wyposażono w podsystem kontroli i porównywania estymowanych danych wielozakresowych z danymi referencyjnymi, pozyskanymi w warunkach laboratoryjnych za pomocą fizycznej kamery hiperspektralnej. W ramach badań opracowano spójny system walidacji, którego miarą końcową jest **współczynnik zgodności widmowej** wyrażany w procentach.
- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – analiza zrekonstruowanego widma w celu wykrywania niewidocznych gołym okiem zmian chemicznych (poziom nawodnienia, wczesne procesy gnilne, utlenianie). We wskazanym module zweryfikowano możliwość klasyfikacji stanu produktów w czasie zbliżonym do rzeczywistego oraz zbadano obciążenie jednostek obliczeniowych (zarówno serwerowych, jak i procesorów mobilnych) oraz zużycie pamięci RAM. W module zastosowano tolerancję dla rozdzielczości mapy spektralnej, która zakłada, że **szybkość klasyfikacji** (utrzymanie przewagi 95% szybkości względem tradycyjnych metod) ma pierwszeństwo przed bezstratną rozdzielczością przestrzenną obrazu. Badania modułu skupiły się na znalezieniu

optymalnego punktu trafności detekcji zmian chemicznych w stosunku do obciążenia procesora urządzenia.

Na poziomie wskazanego etapu określono również **model matematyczny i architekturę kwantyzacji wag sieci neuronowej**, które pozwalają na wielowątkowe wykonywanie obliczeń tensorowych oraz docelową kompresję modelu na potrzeby urządzeń mobilnych współpracujących z chmurą.

## 4. IV poziom TRL – Badania w warunkach laboratoryjnych

W ramach realizacji IV poziomu gotowości technologicznej zintegrowano opracowane wcześniej moduły w działający prototyp systemu i przeprowadzono prace badawcze w warunkach laboratoryjnych w następującym zakresie:

- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – przygotowano zestaw kontrolny 100 zdjęć próbek żywności wykonanych w formatach: *jpg, png, heic* oraz *dng (RAW)*. Określono, że wewnętrzny format plików po normalizacji oświetlenia i separacji światła odbitego będzie miał rozszerzenie: ***.nrgb** (*Normalized RGB*). Wykonano 100 serii testów na zestawie kontrolnym. Algorytm wykazał pewne odchylenia w niektórych seriach testów dla formatów skompresowanych stratnie (*jpg, heic*). Ustalono, że na wynik ma wpływ wbudowane w systemy operacyjne smartfonów automatyczne odszumianie i wyostrzanie krawędzi przez procesor obrazu (**ISP**). Wprowadzono poprawkę do algorytmu (filtr neutralizujący ingerencję ISP) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.
- **Moduł rekonstrukcji widma wielozakresowego** – przygotowano zestaw kontrolny 100 plików wstępnie przetworzonych w formacie ***.nrgb**. Określono, że wygenerowane przez sieć neuronową mapy widmowe będą zapisywane w autorskim formacie macierzowym o rozszerzeniu: ***.mspec** (*Multispectral Data*). Wykonano po 100 serii testów dla zestawu kontrolnego, porównując wyniki z odczytami referencyjnej kamery hiperspektralnej. Algorytm wykazał pewne odchylenie w niektórych seriach testów przy odtwarzaniu pasma bliskiej podczerwieni. Ustalono, że na wynik ma wpływ konwersja precyzji zmiennoprzecinkowej (z *FP32* na *FP16*) na różnych jednostkach obliczeniowych (**GPU/NPU**). Wprowadzono poprawkę do algorytmu normalizacji wag sieci i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.
- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – przygotowano zestaw kontrolny 100 plików map widmowych w formacie ***.mspec** (obejmujących produkty świeże oraz w początkowym stadium utleniania i gnicia). Wykonano po 100 serii testów dla zestawu kontrolnego plików. Podczas każdego testu rejestrowano wygenerowane raporty diagnostyczne (zapisywane w formacie ***.frep** – *Freshness Report*) oraz logowano czas analizy i obciążenie podzespołów. Algorytm wykazał pewne odchylenie w niektórych seriach testów dla produktów o silnie połyskliwej strukturze powierzchni (np. jabłka, pomidory). Ustalono, że na wynik ma wpływ punktowe przesterowanie kanałów jasności w miejscu bezpośredniego odbicia źródła światła. Wprowadzono poprawkę do algorytmu (*maskowanie odblasków spekularnych*) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne, a odchylenia zostały zminimalizowane.

### 4.1. Określenie ryzyk dla IV poziomu TRL wraz z koncepcją ich eliminacji

W celu odniesienia skuteczności realizacji projektu zidentyfikowano kluczowe ryzyka dla etapu badań nad prototypem oraz określono priorytety (stopień procentowy) i sposoby ich wyeliminowania:

- **Ryzyko 1 (Szansa wystąpienia: 65%):** Niespójność wyników wstępnego przetwarzania i rekonstrukcji widma wynikająca z różnic sprzętowych w matrycach aparatów oraz układach obliczeniowych (*SoC/NPU*) różnych producentów smartfonów.

**Rozwiązanie:** Rozszerzenie testów w badaniu o szersze spektrum jednostek mobilnych (różne architektury ARM i matryce światłoczułe) oraz wdrożenie macierzy kalibracyjnej pobierającej parametry optyczne z metadanych *EXIF* zdjęcia przed uruchomieniem głównego algorytmu.

- **Ryzyko 2 (Szansa wystąpienia: 45%):** Niekompatybilność przesyłanych danych pomiędzy modułem rekonstrukcji widma a modułem detekcji anomalii chemicznych i klasyfikacji świeżości.

**Rozwiązanie:** Dokonanie szczegółowego debugowania kodu, ustandaryzowanie wewnętrznej struktury nagłówków plików ***.mspec** oraz zastosowanie metody eliminacji wszystkich błędów i nieścisłości związanych z przesyłaniem danych „krok po kroku".

- **Ryzyko 3 (Szansa wystąpienia: 30%):** Brak poprawnej komunikacji i synchronizacji pomiędzy modułami prototypu (zarówno po stronie urządzenia, jak i w komunikacji z chmurą) skutkujący zawieszaniem się procesu analizy lub wyciekami pamięci RAM podczas przetwarzania dużych partii zdjęć.

**Rozwiązanie:** Zastosowanie zaprogramowanych testów automatycznych (jednostkowych i integracyjnych) oraz uporządkowanie architektury prototypu z wykorzystaniem wzorca architektonicznego **MVC – Model-View-Controller** (pol. *Model-Widok-Kontroler*).

## 5. Grupa docelowa oraz model komercjalizacji produktu

### 5.1. Grupa docelowa

W skład głównej grupy docelowej wchodzą podmioty z sektora **B2B** (*Business-to-Business*) działające w branży rolno-spożywczej, logistycznej oraz handlowej (*FMCG*), które poszukują szybkich, bezinwazyjnych i tanich metod weryfikacji jakości oraz świeżości produktów spożywczych (głównie owoców i warzyw). Bezpośrednimi użytkownikami końcowymi aplikacji mobilnej będą kontrolerzy jakości, magazynierzy, audytorzy dostaw oraz kierownicy działów świeżych produktów w wieku 22–55 lat, wykorzystujący smartfony służbowe w codziennej pracy operacyjnej. Do tej grupy kierowana będzie mobilna aplikacja skanująca współpracująca z chmurą obliczeniową.

Drugim segmentem odbiorców są średnie i duże gospodarstwa rolne oraz sadownicze (**rolnictwo precyzyjne**), a także instytucje i firmy ubezpieczeniowe szacujące szkody w uprawach, do których kierowana będzie usługa zaawansowanej analityki predykcyjnej oraz dostęp do interfejsu API pozwalającego na integrację algorytmu z wewnętrznymi systemami klasy *ERP/WMS*. Szacuje się, że wielkość rynku docelowego w samej Polsce obejmuje ponad **10 000 podmiotów** z sektora dystrybucji żywności (hurtownie spożywcze, centra logistyczne, sieci supermarketów) oraz około **150 000**

**nowoczesnych gospodarstw towarowych** zainteresowanych wdrażaniem rozwiązań z obszaru *AgriTech* i *FoodTech* (w skali całej Unii Europejskiej rynek ten przekracza kilkaset tysięcy potencjalnych klientów biznesowych).

### 5.2. Model biznesowy (sprzedażowy)

Model biznesowy opierał się będzie na dystrybucji oprogramowania w modelu **SaaS** (*Software as a Service*) i zostanie podzielony na dwa główne filary (segmenty):

- **Segment MŚP oraz użytkowników indywidualnych (mniejsze hurtownie, lokalne sklepy spożywcze, niezależni sadownicy i rolnicy):** Usługa dostępu do aplikacji mobilnej zostanie podzielona na wersję **Freemium** (darmową) oraz opcję **Premium** (płatną). W opcji darmowej użytkownik otrzyma możliwość wykonania do 50 skanów próbnych miesięcznie wraz z podstawowym odczytem wskaźnika świeżości, co pozwoli na bezkosztowe przetestowanie narzędzia i zbudowanie szerokiej rozpoznawalności marki w branży. W opcji płatnej (*Premium*), rozliczanej w formie abonamentu miesięcznego lub rocznego, udostępniona zostanie możliwość nielimitowanego skanowania partii towaru, wykrywania wczesnych procesów gnilnych w pełnej rozdzielczości widmowej, generowania szczegółowych raportów diagnostycznych (***.frep**) oraz eksportu dokumentacji kontrolnej do formatów PDF/CSV.
- **Segment instytucjonalny i korporacyjny (duże sieci handlowe, centra dystrybucyjne, zakłady przetwórstwa spożywczego):** W segmencie instytucjonalnym, do którego kierowana jest głównie usługa masowej kontroli jakości oraz integracji systemowej (API), sporządzana będzie **umowa licencyjna**. Pozwoli ona w pierwszym etapie (tzw. *okres pilotażowy*) za darmo korzystać z systemu rekonstrukcji widma i klasyfikacji świeżości w ograniczonych limitach ilościowych (np. do 1000 skanów lub dla jednego wybranego magazynu). Następnie, w zależności od wykupionej licencji (**opłata abonamentowa roczna**), klient biznesowy otrzyma kilka opcji płatnych do wyboru, dopasowanych do wewnętrznych potrzeb swojej organizacji – obejmujących m.in. integrację z systemami magazynowymi *WMS*, nielimitowaną przestrzeń w chmurze na dane historyczne, obsługę strumieni wideo z kamer na liniach sortowniczych oraz gwarantowane wsparcie techniczne (*SLA*).

## 6. V poziom TRL – Weryfikacja koncepcji w środowisku zbliżonym do rzeczywistego

W celu połączenia zaprogramowanych komponentów zostanie zastosowany wzorzec architektoniczny **MVC** (z ang. *Model-View-Controller*, pol. *Model-Widok-Kontroler*), który służy do organizowania struktury aplikacji. W tym celu zaprogramowany zostanie dodatkowy moduł **Kontrolera**. Jego zadaniem będzie koordynacja pracy aplikacji hybrydowej poprzez przyjmowanie danych obrazowych oraz macierzy widmowych i reagowanie na nie. Będzie on zarządzał aktualizacją modelu aplikacji oraz odświeżaniem widoków interfejsu użytkownika na urządzeniu mobilnym. W etapie zostaną przeprowadzone prace koncentrujące się na zweryfikowaniu komponentów i podstawowych podsystemów technologii w środowisku zbliżonym do rzeczywistego (symulowane warunki oświetlenia hali magazynowej oraz chłodni spożywczej).

- **Kontroler** – zostanie zaprogramowany celem koordynowania pracy pozostałych modułów systemu. W opisanym etapie zostanie sprawdzone działanie kontrolera i przeprowadzone testy jego stabilności (poprzez jego wielokrotne włączanie i wyłączanie oraz symulowanie przerw w połączeniu z chmurą; błędy powodujące destabilizację pracy kontrolera będą korygowane do momentu, aż zostanie wykonany pełny cykl bez błędów). Powyższe pozwoli zweryfikować, czy prawidłowo odbiera on dane wejściowe z aparatu, dokonuje ich podstawowej identyfikacji i prawidłowo przesyła je do wybranych modułów przetwarzania. W kontrolerze zostaną zdefiniowane wtyczki (interfejsy komunikacyjne) do wszystkich zaprogramowanych wcześniej modułów oraz podstawowa weryfikacja danych (i ich typów, m.in. walidacja formatów wejściowych *jpg, png, heic, dng* oraz pośrednich ***.nrgb, *.mspec, *.frep**), jakie mają wyjść do danego modułu. Zostanie także przetestowane działanie rozpoznawania danych dla poszczególnych modułów. W tym celu moduł zostanie poddany testom na danych kontrolnych dla każdej z wtyczek Kontrolera dedykowanej dla konkretnego modułu. Zostanie także dokonana weryfikacja reakcji modułu na dane celowo „uszkodzone" (np. zmieniony typ danych, niepełny nagłówek macierzy widmowej lub zerowy rozmiar pliku zdjęcia). W przypadku niewłaściwej reakcji zostanie dokonana analiza, która ustali przyczynę błędu. Następnie zostaną wprowadzone zmiany programistyczne w obszarze warunków weryfikujących zgodność danych. Pomyślny test prawidłowego działania kontrolera (tj. uzyskania zwrotu informacji o błędach w danych bez zawieszenia aplikacji) pozwoli na jego pełną integrację z wcześniej zaprogramowanymi modułami.
- **Moduł kalibracji optycznej i wstępnego przetwarzania obrazu RGB** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (zgodnie z wymogami weryfikacji w środowisku zbliżonym do rzeczywistego zwiększono bazę testową z 100 do **1000 plików zdjęć** partii owoców i warzyw wykonanych w symulowanych warunkach oświetlenia magazynowego, w zakresie prawidłowej normalizacji oświetlenia i konwersji do formatu ***.nrgb**). Analizie podlegała także kompletność znormalizowanych danych oraz skuteczność odrzucania kadrów poruszonych i prześwietlonych. Ewentualne błędy w opisanym zakresie (wynikające m.in. z migotania oświetlenia jarzeniowego *50 Hz* w halach magazynowych) zostaną wyeliminowane poprzez poprawki programistyczne i kolejne testy na tych samych 1000 plikach (aż do poprawnego skomunikowania się z modułem kontrolera i poprawnego odczytu poleceń otrzymanych z Kontrolera).
- **Moduł rekonstrukcji widma wielozakresowego** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (testu dokonano na próbnej bazie **1000 plików** wstępnie przetworzonych obrazów ***.nrgb**, w zakresie prawidłowej estymacji widma i generowania plików macierzowych ***.mspec**). Zweryfikowano jakość komunikacji danych pomiędzy urządzeniem mobilnym a serwerem obliczeniowym oraz kompatybilność z pozostałymi współpracującymi modułami systemu. Przeprowadzono procedurę sprawdzającą jakość zrekonstruowanych informacji widmowych na plikach testowych względem pomiarów referencyjnych. W przypadku błędów spowodowanych przeciążeniem kontrolera, przekroczeniem limitu czasu odpowiedzi (tzw. *timeout*) lub błędami alokacji pamięci modelu rekonstrukcji widma, zostaną one usunięte poprzez analizę wyników i dokonanie korekty programistycznej w kodzie (optymalizacja kolejkowania zadań i buforowania tensorów). Następnie ponownie zostanie wykonany test na tych samych 1000 plikach.

- **Moduł detekcji anomalii chemicznych i klasyfikacji świeżości** – dokonano integracji modułu z kontrolerem. Przetestowano działanie samego modułu oraz w relacji z kontrolerem (testu dokonano na próbnej bazie **1000 plików** map widmowych ***.mspec** oraz sekwencji kadrów wideo, w zakresie prawidłowej detekcji zmian chemicznych i klasyfikacji świeżości w czasie zbliżonym do rzeczywistego). Zweryfikowano jakość odczytu danych wyjściowych w postaci poprawności generowanych raportów diagnostycznych (***.frep**) oraz wizualnej nakładki mapy świeżości prezentowanej na ekranie smartfona. Sprawdzono jakość komunikacji danych i kompatybilność z pozostałymi współpracującymi modułami systemu. W przypadku błędów spowodowanych przeciążeniem kontrolera lub modułu klasyfikacji podczas ciągłego skanowania partii towaru, zostaną one usunięte poprzez analizę wyników i dokonanie korekty programistycznej w kodzie. Następnie ponownie zostanie wykonany test na tych samych 1000 plikach.

# 7. Analiza SWOT projektu wraz z oszacowaniem prawdopodobieństwa

W celu uporządkowania i przeanalizowania informacji strategicznych dotyczących rozwijanej technologii estymacji widma wielozakresowego ze standardowego obrazu RGB, przeprowadzono **analizę SWOT** z podziałem na cztery główne grupy czynników (wewnętrzne pozytywne i negatywne oraz zewnętrzne pozytywne i negatywne). Dla każdego ze zidentyfikowanych czynników oszacowano procentowe prawdopodobieństwo jego wystąpienia, posiadania lub zrealizowania wraz z komentarzem analitycznym.

## 7.1. S (Strengths) – Mocne strony (czynniki wewnętrzne pozytywne)

- **Wysoka przewaga szybkości i niskiego kosztu wdrożenia względem kamer hiperspektralnych (prawdopodobieństwo utrzymania parametru: 95%).** *Komentarz:* Eliminacja konieczności zakupu specjalistycznego sprzętu optycznego na rzecz zwykłego aparatu w smartfonie oraz o 95% szybszy czas detekcji stanowią główny atut technologiczny potwierdzony już w badaniach laboratoryjnych.
- **Skuteczność klasyfikacji struktury powierzchni i zmian chemicznych wyższa o 21,37% od klasycznych algorytmów analizy tekstur (prawdopodobieństwo posiadania cechy: 92%).** *Komentarz:* Wysokie prawdopodobieństwo wynika z zastosowania autorskiego modelu uczenia głębokiego oraz walidacji na danych referencyjnych w formatach ***.nrgb** oraz ***.mspec**.
- **Nowoczesny interfejs mobilny oparty na zasadzie „im mniej kroków do rezultatu, tym lepiej" (szansa wystąpienia: 98%).** *Komentarz:* W tym obszarze nie są wymagane nadzwyczajne działania korygujące, ponieważ architektura MVC oraz proces skanowania jednym przyciskiem zostały precyzyjnie zaplanowane i zweryfikowane.
- **Skalowalna architektura hybrydowa łącząca obliczenia brzegowe (Edge AI) z chmurą obliczeniową oraz otwartym API (prawdopodobieństwo osiągnięcia: 90%).** *Komentarz:* Pozwala na jednoczesną obsługę klientów indywidualnych (aplikacja mobilna) oraz dużych sieci logistycznych (integracja z systemami WMS/ERP).

## 7.2. W (Weaknesses) – Słabe strony (czynniki wewnętrzne negatywne)

- **Wrażliwość algorytmu na skrajnie niekorzystne warunki oświetleniowe oraz silne odblaski spekularne na błyszczących owocach (prawdopodobieństwo wystąpienia problemu: 35%).** *Komentarz:* Świadomość tej słabej strony na wczesnym etapie pozwoliła na wdrożenie filtrów maskujących odblaski oraz podsystemu odrzucania kadrów prześwietlonych, co redukuje pierwotne ryzyko błędów.
- **Rozbieżność parametrów optycznych matryc aparatów oraz algorytmów ISP u różnych producentów smartfonów (prawdopodobieństwo wystąpienia: 85%).** *Komentarz:* Wymaga ciągłego utrzymywania i aktualizowania macierzy kalibracyjnej pobierającej dane z nagłówków EXIF dla nowych modeli telefonów wchodzących na rynek.
- **Zależność pełnej analityki wielozakresowej i generowania raportów zbiorczych od stabilnego połączenia internetowego z chmurą (prawdopodobieństwo wystąpienia utrudnień: 30%).** *Komentarz:* W magazynach podziemnych lub chłodniach o grubych ścianach zasięg sieci komórkowej bywa ograniczony, dlatego konieczne jest buforowanie plików ***.nrgb** w pamięci lokalnej urządzenia.
- **Wysokie zapotrzebowanie na moc obliczeniową GPU na etapie trenowania i douczania sieci neuronowej dla nowych gatunków żywności (prawdopodobieństwo wystąpienia bariery kosztowej: 40%).** *Komentarz:* Rozbudowa bazy wiedzy modelu o kolejne kategorie produktów wymaga utrzymania kosztownej infrastruktury serwerowej i laboratoryjnej.

## 7.3. O (Opportunities) – Szanse (czynniki zewnętrzne pozytywne)

- **Rosnący nacisk regulacyjny i ekonomiczny w Unii Europejskiej na redukcję marnowania żywności w łańcuchach dostaw (szansa na korzystny rozwój rynku: 85%).** *Komentarz:* Bardzo silna szansa rynkowa – sieci handlowe i centra dystrybucyjne aktywnie poszukują narzędzi zmniejszających straty magazynowe świeżych produktów.
- **Możliwość pozyskania dotacji badawczo-rozwojowej z funduszy UE lub NCBR na dalszą komercjalizację technologii (szansa na powodzenie: 40%).** *Komentarz:* Umiarkowany poziom procentowy wynika z dużej konkurencji w konkursach grantowych; staranne przygotowanie dokumentacji projektowej (zgodnej ze skalą TRL) pozwala jednak realnie zwiększyć szansę na uzyskanie finansowania.
- **Rozszerzenie zastosowań opracowanego silnika rekonstrukcji widma na inne branże, np. dermatologię mobilną lub kontrolę powłok lakierniczych (szansa wdrożenia w przyszłości: 55%).** *Komentarz:* Elastyczna budowa modułowa pozwala w kolejnych latach na dywersyfikację źródeł przychodu poza sektorem spożywczym.

## 7.4. T (Threats) – Zagrożenia (czynniki zewnętrzne negatywne)

- **Wprowadzenie przez wiodących producentów smartfonów natywnych sensorów wielospektralnych lub wbudowanych funkcji AI o podobnym działaniu (szacowane ryzyko wystąpienia: 20%).** *Komentarz:* Ryzyko w krótkim terminie jest niskie ze względu na koszty sprzętowe po stronie producentów telefonów, jednak w perspektywie kilkuletniej wymaga budowania przewagi w postaci wyspecjalizowanej bazy danych produktów i integracji B2B.

- **Opór personelu magazynowego oraz mniejszych hurtowni przed zastąpieniem tradycyjnej oceny organoleptycznej systemem algorytmicznym (szacowane ryzyko wystąpienia: 35%).** *Komentarz:* W celu minimalizacji tego zagrożenia wprowadzono darmowy plan Freemium (do 50 skanów) oraz bezpłatne wdrożenia pilotażowe budujące zaufanie do wskazań aplikacji.
- **Drastyczny wzrost cen energii oraz usług chmurowych (Cloud GPU) obniżający rentowność modelu subskrypcyjnego SaaS (szacowane ryzyko wystąpienia: 25%).** *Komentarz:* Zagrożenie to jest ograniczane poprzez kwantyzację wag sieci neuronowej (FP16) i przenoszenie części obliczeń bezpośrednio na procesory mobilne użytkowników.
- **Możliwa zmiana prawna i zaostrzenie przepisów UE (np. AI Act oraz normy certyfikacji systemów jakości żywności) wpływające strategicznie na dopuszczenie systemu do obrotu (szacowane ryzyko wystąpienia: 10%).** *Komentarz:* Choć jednostkowe ryzyko jest stosunkowo niskie (10%), przy kumulacji kilku czynników regulacyjnych może ono opóźnić komercjalizację, dlatego system raportowania ***.frep** od początku projektowany jest z zachowaniem pełnej przejrzystości i audytowalności wyników.

# 8. VI poziom TRL – Demonstracja modelu prototypu w warunkach zbliżonych do rzeczywistych

Aplikacja osiągnęła pełną integrację wszystkich modułów pod nadzorem **Kontrolera** i została przygotowana do zaawansowanych testów demonstracyjnych w warunkach wiernie odwzorowujących docelowe środowisko operacyjne pod kątem: obciążenia generowanego na serwerach chmurowych (rekonstrukcja widma wielozakresowego i głęboka analiza anomalii chemicznych dla strumieni danych), jakości zwracanych wyników diagnostycznych oraz stabilności działania na urządzeniach mobilnych i terminalach stacjonarnych korzystających z różnych wersji systemów operacyjnych (*Android, iOS* oraz przeglądarkowe systemy centralne). W ramach szóstego poziomu gotowości technologicznej zaplanowano również przeprowadzenie testów użyteczności (*usability testing*), w których próby zostaną dokonane bezpośrednio na przyszłych użytkownikach końcowych (kontrolerach jakości, magazynierach i sadownikach). Testy typu *usability* dają bezpośrednią informację na temat tego, w jaki sposób użytkownicy korzystają z zaprojektowanego systemu w codziennej pracy – posiadają one inną, kluczową wartość praktyczną niż testy wykonywane wcześniej wyłącznie przez inżynierów biorących aktywny udział w tworzeniu aplikacji.

## 8.1. Testy serwerowe (obciążeniowe) i testy użytkowe (usability)

Badania na VI poziomie TRL zostaną podzielone na dwie główne grupy: **testy serwerowe** oraz **testy użytkowe**.

**Testy serwerowe:** Będą polegały na symulowaniu obciążenia maksymalnego dla równoczesnej obsługi **50 000 użytkowników** systemu estymacji widma i klasyfikacji świeżości przesyłających żądania analityczne w tym samym czasie. Testy będą trwały w okresach **10-dniowych bez przerw** celem pełnej realizacji długodystansowych prób obciążeniowych (tzw. *stress & soak testing*). Cały proces będzie podlegał nieustannemu monitoringowi telemetrii, a wyniki kontrolne (czas odpowiedzi API, utylizacja

jednostek GPU/CPU, alokacja pamięci RAM oraz przepustowość bazy danych) będą zapisywane w równych interwałach czasowych. W czasie testów sprawdzone zostanie, czy moc obliczeniowa klastrów serwerowych jest optymalna do zaprojektowanych obliczeń tensorowych i docelowej liczby użytkowników. Sprawdzone zostanie także, czy:

- 1. dane w systemie bazowym (mapy widmowe ***.mspec** oraz raporty świeżości ***.frep**) są odpowiedniej jakości po przeprowadzeniu rekonstrukcji widma i nie ulegają przekłamaniom pod wpływem masowego przetwarzania współbieżnego,
- 2. wydajność systemu (utrzymanie zakładanej przewagi **95% szybkości** analizy) utrzymuje się na przewidywanym poziomie i nie występuje zjawisko dywergencji czasów odpowiedzi lub wycieków pamięci.

**Testy użytkowe:** Będą polegały na ponownym, masowym sprawdzeniu jakości i powtarzalności algorytmu na rozbudowanej bazie **30 000 plików** zdjęć partii produktów spożywczych poddawanych kalibracji do formatu ***.nrgb**, rekonstrukcji widmowej do formatu ***.mspec** oraz końcowej klasyfikacji świeżości (***.frep**), w celu weryfikacji, czy jakość danych diagnostycznych utrzymuje się na stabilnym, zakładanym poziomie. Równolegle zostaną wykonane testy na użytkownikach rzeczywistych w celu sprawdzenia rzeczywistego zachowania się aplikacji w warunkach zbliżonych do operacyjnych (hale przyjęć towaru, giełdy rolno-spożywcze). W tym celu zostanie zaangażowana grupa **200 użytkowników systemu** nieznających wcześniej aplikacji. Osoby te otrzymają zestawy kontrolne próbek owoców i warzyw oraz karty zadań – ich zadaniem będzie samodzielne zainstalowanie aplikacji na urządzeniu mobilnym, uruchomienie jej i wykonanie krok po kroku instrukcji skanowania oraz odczytu raportu świeżości. Powyższe pozwoli na wykonanie pełnych czynności analitycznych, do których aplikacja została zaprojektowana (test użytkowy). Ewentualne problemy związane z ergonomią obsługi aplikacji lub działaniem algorytmu zostaną rozwiązane w kolejnym poziomie gotowości technologicznej (TRL VII). Na tym etapie planowane jest także uzyskanie ustrukturyzowanej informacji zwrotnej (ankiety *UX/Usability*) od użytkowników w zakresie intuicyjności i zrozumienia obsługi systemu.

## 8.2. Efekt końcowy VI poziomu TRL

W efekcie końcowym VI poziomu gotowości technologicznej zostanie uzyskana kompleksowo przetestowana wersja demonstracyjna aplikacji (zarówno w wersji mobilnej dla systemów *Android/iOS*, jak i modułu centralnego w chmurze) zweryfikowana w warunkach wiernie odwzorowujących rzeczywiste obciążenie produkcyjne. Ewentualne korekty programistyczne, optymalizacje interfejsu oraz poprawki wykrytych błędów zostaną wykonane w kolejnym poziomie gotowości technologicznej (w ramach prac rozwojowych). Sam sposób działania aplikacji, proces wykonywania skanów oraz interpretacji raportów świeżości na tym etapie powinien zostać w pełni zrozumiany i zaakceptowany przez docelowych użytkowników.

## 8.3. Ryzyka technologiczne dla VI poziomu TRL wraz z koncepcją ich eliminacji

Zgodnie z wymogami ostatniego etapu badań przemysłowych zidentyfikowano kluczowe ryzyka technologiczne mogące wystąpić podczas demonstracji prototypu pod pełnym obciążeniem oraz określono sposoby ich eliminacji:

- **Ryzyko 1:** Trudności z wiernym odwzorowaniem obciążenia rzeczywistego w testach serwerowych dla równoczesnej rekonstrukcji widma wielozakresowego przy symulacji **50 000 użytkowników** przesyłających dane w tym samym czasie.

**Rozwiązanie:** W tym celu zostaną wykorzystane specjalistyczne narzędzia zewnętrzne do testów obciążeniowych chmury (np. rozproszone klastry *Apache JMeter / Locust*) oraz zostaną zaprojektowane własne skrypty symulacyjne generujące syntetyczny strumień zapytań API z plikami ***.nrgb** celem precyzyjnego zasymulowania wymaganego obciążenia w 10-dniowym cyklu pomiarowym.

- **Ryzyko 2:** Błędy obsługi aplikacji przez grupę 200 nowych użytkowników podczas testów użyteczności (*usability testing*), takie jak wykonywanie zdjęć ze zbyt dużej odległości, pod niewłaściwym kątem lub nieprawidłowa interpretacja wskaźników na ekranie wynikowym.

**Rozwiązanie:** Wdrożenie w interfejsie aplikacji interaktywnego samouczka powitalnego (*onboarding*) oraz dynamicznych ramek celowniczych na podglądzie kamery, które w czasie rzeczywistym informują użytkownika o prawidłowej odległości od skanowanej partii towaru przed wyzwoleniem migawki.

- **Ryzyko 3:** Wystąpienie wąskich gardeł (tzw. *bottlenecks*) w kolejkowaniu zadań na serwerowych kartach GPU podczas jednoczesnego przetwarzania **30 000 plików** testowych, prowadzące do spadku wydajności poniżej zakładanego progu szybkości.

**Rozwiązanie:** Zastosowanie mechanizmu automatycznego skalowania horyzontalnego instancji obliczeniowych w chmurze (*Auto-Scaling*) oraz asynchronicznych kolejek komunikatów (*RabbitMQ / Redis*) równoważących ruch pomiędzy węzłami obliczeniowymi.